

Núcleo de Inteligência Artificial - Universidade La Salle Canoas

Estatística aplicada para AI

Fornecem as técnicas para algoritmos identificarem padrões, como regressão linear, regressão logística e algoritmos de agrupamento.

- a) **Medidas de Tendência Central:** Média, Mediana e Moda (Foco em: Tratamento de dados ausentes e preenchimento de lacunas).
- b) **Medidas de Dispersão:** Variância e Desvio Padrão (Foco em: Entender o espalhamento dos dados e base para a Normalização).
- c) **Análise de Correlação:** Coeficiente de Pearson (Foco em: Identificar quais variáveis realmente impactam o modelo e eliminar dados redundantes).
- d) **Inferência Estatística e Amostragem:** População vs. Amostra (Foco em: Como o modelo generaliza o que aprendeu no treino para o mundo real).
- e) **Distribuições de Probabilidade:** Distribuição Normal/Gaussiana e Softmax (Foco em: Inicialização de pesos e saída final de classificação).
- f) **Métricas de Erro e Performance:** Erro Médio Quadrático (MSE), Erro Absoluto (MAE) e Acurácia (Foco em: Medir o sucesso do treinamento).

Medidas de Tendência Central

Média

É a soma de todos os valores pertencentes a um conjunto de dados e dividindo o resultado pela quantidade de elementos. Para as AIs, é uma ferramenta de equilíbrio.

Aplicação:

Tratamento de Dados Faltantes: Quando uma base de dados tem buracos (ex: idades faltando em um cadastro), usamos a média do grupo para preencher esses vazios sem alterar o comportamento geral do conjunto.

Normalização: Para que um neurônio não dê importância demais a um número grande (ex: Salário) e ignore um pequeno (ex: Idade), usamos a média para centralizar todos os dados em torno de zero.

Fórmula:

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$$

$\bar{X}$ (O "x" com barra): É o **resultado final**, a nossa **Média**. No exemplo, é o valor **5**.

Σ (Sigma Maiúsculo): Esse símbolo bonitão é apenas uma ordem de comando. Ele diz:
"Some tudo o que vem depois de mim".

X_i (O elemento): Representa cada número individual da sua lista (o 2, o 4, o 6 e o 8).
O "i" é como um índice (1º número, 2º número...).

n (o divisor): É a quantidade total de itens que você tem. No nosso caso temos quatro números (2, 4, 6, 8), o **$n = 4$** .

Exemplo:

Imagine que temos os erros de 4 predições de uma IA: 2, 4, 6 e 8.

- 1) Identificamos os dados ($\mathbf{X}_i$): $x_1=2$, $x_2=4$, $x_3=6$ e $x_4=8$
- 2) Contamos quantos são (n): São 4 números.
- 3) Executamos o Sigma (Σ) $2 + 4 + 6 + 8 = 20$.
- 4) Finalizamos a fórmula ($\bar{\mathbf{X}}$): $20 \div 4 = 5$

Fixação:

- a) Uma rede neural processou 5 imagens. O tempo de processamento de cada uma foi: 10ms, 12ms, 15ms, 13ms e 10ms. Qual o tempo médio de processamento por imagem?
- b) Em uma tabela de "Idade de Clientes", você encontrou 4 registros: 20, 30, 40 e 50 anos. No 5º registro, o dado está faltando. Se decidirmos preencher esse dado faltante com a média dos outros quatro, qual valor será inserido?

Mediana

Diferente da média, a Mediana é o valor central que divide seus dados ao meio. Na Engenharia de IA, ela é o nosso "filtro de ruído". Para achar a Mediana (Md), primeiro precisamos ordenar os dados (o Rol). O cálculo também depende se o número de elementos (n) do conjunto é par ou ímpar.

Aplicação:

- **Resistência a Outliers (Valores Discrepantes):** Imagine que você treina uma IA com salários. Se houver um bilionário na lista, a **Média** vai lá para o alto e engana o modelo. A **Mediana** ignora esse valor extremo e foca no que é comum.
- **Limpeza de Dados Sujos:** Quando os sensores (como câmeras ou termômetros) falham e geram um número absurdo (ex: um sensor de temperatura marcando 500°C por erro técnico), usamos a Mediana para ignorar esse erro e manter o treinamento estável.

Formula:

1) Se for **par**: A mediana é a média dos dois valores centrais.

$$\text{Mediana} = \frac{X\left(\frac{n}{2}\right) + X\left(\frac{n}{2} + 1\right)}{2}$$

2) Se for **ímpar**: A mediana é a posição central

$$\text{Mediana} = X\left(\frac{n+1}{2}\right)$$

(Obs.: Considerando um conjunto com quantidade par de elementos “n”)

$x(n/2)$: É o valor que está na posição da "primeira metade"

$x(n/2 + 1)$: É o valor que está na posição imediatamente seguinte ("segunda metade").

Exemplo:

Imagine os tempos de resposta de uma IA em segundos: **1.2, 0.5, 30.0, 0.8, 1.0** .

- **Criar o Rol (Ordenar):** 0.5, 0.8, 1.0, 1.2, 30.0
- **Contar os itens (n):** Temos **5** itens (Ímpar)
- **Aplicar a posição:** $(5+1) / 2 = 3^{\text{a}}$ posição
- **Identificar o valor:** O 3º item é o **1.0**

Nota: Repare que o valor **30.0** (muito alto) não afetou a Mediana, mas destruiria a Média.

Fixação:

- a) Uma rede neural classificou 7 imagens com as seguintes confianças (0 a 100): 85, 90, 70, 95, 60, 100, 80. Qual a Mediana de confiança desse lote? (Dica: coloque em ordem primeiro!).
- b) Analisando o uso de memória de 6 servidores: 4GB, 8GB, 2GB, 16GB, 4GB, 32GB. Qual é a Mediana de consumo de memória deste cluster?

Moda

Ao monitorar os erros de um modelo por uma hora e obtive os seguintes códigos de erro: **404, 500, 404, 403, 500, 404, 502**. É simplesmente o valor que **mais se repete** em um conjunto de dados. Na IA, ela é a nossa ferramenta para **Dados Categóricos** (textos, classes, etiquetas).

Aplicação:

- **Preenchimento de Categorias (Imputação de Classes):** Se você tem uma base de dados de "Tipos de Veículos" e em alguns registros a coluna está vazia, você não pode tirar a "média" entre um Carro e uma Moto. Você usa a **Moda** (o tipo que mais aparece, ex: "Sedan") para preencher o vazio.
- **Voto Majoritário (Ensemble Learning):** Em sistemas de IA avançados, onde várias redes neurais "votam" no que viram em uma imagem, o resultado final escolhido é a **Moda** das respostas. Se 3 IAs dizem "Gato" e 1 diz "Cachorro", a resposta final é a Moda: "Gato".

Formula:

A Moda não possui uma fórmula algébrica complexa como a média. Ela é definida pela frequência.

Mo = Valor com maior frequência absoluta (f_i)

- ***f_i***: É a contagem de quantas vezes cada item aparece.
- **Amodal**: Quando nenhum valor se repete.
- **Bimodal**: Quando dois valores diferentes empatam no topo da repetição

Exemplo:

Imagine as etiquetas de saída de um classificador de objetos em um vídeo: [Pessoa, Carro, Pessoa, Árvore, Pessoa, Carro]

1. Contagem (fi):

- Pessoa: 3 vezes
- Carro: 2 vezes
- Árvore: 1 vez

2. Identificar a maior frequência: O valor “pessoa” aparece mais.

3. Resultado: Mo = Pessoa

Fixação:

a) Uma base de dados de sensores de temperatura registrou: 22°C, 25°C, 22°C, 28°C, 22°C, 30°C.

Qual é a temperatura modal desse sensor?

b) Monitorando os erros de um modelo por uma hora e obteve os seguintes códigos de erro: 404, 500, 404, 403, 500, 404, 502.

1) Qual é a Moda desses erros?

2) Se você fosse o engenheiro, em qual erro focaria primeiro baseado apenas na estatística?

Medidas de Dispersão: Variância e Desvio Padrão

Se a Média diz onde os dados estão "amontoados", a Dispersão diz o quão espalhados eles estão. Na IA, isso é o que separa um modelo estável de um modelo que chuta valores aleatórios.

Variância

A Variância mede a distância média de cada dado em relação à média do conjunto.

Aplicação:

Na Engenharia de IA: Ela indica a Instabilidade. Se a variância do erro da sua IA é alta, significa que ela acerta muito em alguns casos e erra feio em outros. Queremos uma variância baixa e controlada.

Variância Populacional (σ^2):

É aplicada quando tem todos os dados possíveis do universo que se está estudando.

- **Exemplo:**

Você quer a variância da idade de todos os funcionários da sua empresa (e você tem a lista completa de todos os 50 funcionários).

- Divisor: Você divide pelo número total de itens (n).

- **Formula:**

$$\sigma^2 = \frac{\sum (x_i - \bar{x})^2}{n}$$

Ordem discriminada para o cálculo da Variância populacional (geral):

$\bar{x}$: calcular a média;

x_i : dado individual do conjunto;

$\sum$: Representa do somatório total dos desvios individuais somados após serem elevados ao quadrado $(x_i - \bar{x})^2$.

Aqui calcula-se cada desvio $(x_i - \bar{x})$ – diferença do dado menos a média, eleva-se ao quadrado e soma-se os resultados;

“n”: total de elemento do conjunto

σ^2 : é o resultado do somatório ($\sum$) dividido pelo número total de elementos (n), resultando na variância.

Fixação:

Lembrete: Use esta quando você tem o conjunto total de dados.

a) Um pequeno modelo de IA processou apenas **4** requisições. Os erros de tempo (em ms) foram: **2, 4, 6 e 8**.

1. Calcule a média (). $\bar{X}$
2. Calcule a Variância Populacional (σ^2)

(Dica: Como são apenas esses 4 dados no universo do teste, use o divisor $n=4$).

b) Um rack de servidores possui exatamente **5 sensores** de temperatura. Em um momento crítico, as leituras foram: **30°C, 32°C, 30°C, 35°C e 33°C**.

1. Encontre a média das temperaturas.
2. Calcule a Variância Populacional (σ^2) para entender o quão instável está o resfriamento desse rack específico.

Variância Amostral (s^2):

É aplicada quando tem todos os dados possíveis do universo que se está estudando.

Exemplo:

Você quer saber a variância do tempo de resposta de uma IA no mundo, mas você só testou 100 vezes no seu computador.

Divisor: Você divide pelo número total de itens ($n-1$).

Formula:

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1}$$

Ordem discriminada para o cálculo da Variância populacional (geral):

$\bar{x}$: calcular a média;

x_i : dado individual do conjunto;

Σ : Representa do somatório total dos desvios individuais somados após serem elevados ao quadrado $(x_i - \bar{x})^2$.

Aqui calcula-se cada desvio $(x_i - \bar{x})$ – diferença do dado menos a média, eleva-se ao quadrado e soma-se os resultados;

“n-1”: total de elemento do conjunto (- 1)

s^2 : é o resultado do somatório (Σ) dividido pelo número total de elementos (n-1), resultando na variância.

Desvio Padrão

É a **distância média** (grau de dispersão) que os seus dados estão em relação à média do grupo (). Ele funciona como uma "Régua de Erro".

- **Desvio Padrão Baixo:** Significa que os dados estão "comportados" e muito próximos da média. (Ex: Uma linha de produção muito precisa).
- **Desvio Padrão Alto:** Significa que os dados estão "espalhados" e longe da média. (Ex: Um processo instável ou imprevisível).

- **Formula:**

$$s = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n - 1}}$$

$\bar{x}$: calcular a média;

x_i : dado individual do conjunto;

$\sum$: Representa do somatório total dos desvios individuais somados após serem elevados ao quadrado $(x_i - \bar{x})^2$.

Aqui se calcula cada desvio $(x_i - \bar{x})$ – diferença do dado menos a média, eleva-se ao quadrado e soma-se todos os resultados;

“n - 1”: total de elemento do conjunto – 1.

"s" : Desvio Padrão Amostral (resultado)

Exemplo:

Imagine que o tempo de processamento de três tarefas na IA foi de 2s, 4s e 6s.

1. Média ($\bar{x}$): 4s.

2. Variância (s^2):
$$s^2 = \sqrt{\frac{(2-4)^2 + (4-4)^2 + (6-4)^2}{n-1}} = \frac{4+0+4}{2} = 4s^2$$

3. Desvio Padrão (s): $s = \sqrt{4} = 2 \text{ seg}$

Interpretação: O tempo médio é 4 segundos, com uma variação padrão de 2 segundos para cima o para baixo.

Fixação:

- a) Um sensor de temperatura em um servidor registrou três leituras em uma hora: **20°C, 24°C e 28°C**. Sabendo que a variância dessas leituras é 16, calcule o Desvio Padrão desse sensor.
- b) Monitorando o erro de predição de uma IA em 5 testes. Os valores encontrados foram: **2, 3, 5, 7 e 8**. Calcule a média, a variância amostral e, por fim, o **Desvio Padrão** desse conjunto de erros.

Atividades de fixação no forms:

<https://docs.google.com/forms/d/1fuu8Nj6tjhI7dprVhwpOWmuiKDpJw6YR23imXMwdFtQ/edit>

Gabarito no forms:

https://docs.google.com/forms/d/1F9BbDz_2nZTWhNvI7Gk7fSEAAKwGE-N6vOCD5_8imqE/edit