




Núcleo de Inteligência Artificial – Universidade LaSalle Canoas

Introdução a Redes Neurais



Diogo G. Bonofre dos Santos

Assuntos

1. Análise exploratória de dados
2. Por quê EDA existe?
3. Problemas que a EDA tenta mitigar
4. Contexto Histórico
5. Classificação de dados estatísticos
6. Classificação de dados computacionais
7. Dataset Titanic e sua estrutura
8. Prática

Análise Exploratória de Dados

A Análise Exploratória de Dados existe porque datasets reais não nascem prontos para modelagem. Eles contêm:

- Observações incompletas;
- Erros de medição;
- Pressupostos ocultos;
- Variáveis ambíguas;
- Amostras enviesadas;
- Outliers;
- Tipos de dados misturados;
- Sumarizações enganosas;
- Contexto social, histórico ou operacional.

Portanto, o objetivo da EDA não é meramente visualizar dados . O objetivo é reduzir a incerteza sobre nossas premissas antes de modelarmos a solução.

Por quê EDA existe?

Antes de modelar, precisamos entender que tipo de objeto estamos analisando.

Um dataset não é meramente uma tabela. Ele é resultado de um processo:

1. Fenômeno do mundo real
2. Medição/registo
3. Representação dos dados
4. Limpeza e transformação
5. Análise
6. Modelagem
7. Decisão

Em cada etapa, informação pode ser perdida, distorcida, simplificada ou enviesada.

Problemas que a EDA tenta mitigar

Dados são incompletos

Alguns valores estão ausentes porque não foram coletados, não se aplicam, foram perdidos, censurados ou omitidos intencionalmente.

Exemplo:

- A idade pode estar ausente para alguns passageiros.
- A informação da cabine pode estar ausente para muitos passageiros.

Questão: A ausência é aleatória ou carrega informação?

Problemas que a EDA tenta mitigar

Dados são codificados, não autoexplicativos

Variáveis podem parecer simples, mas esconder complexidade semântica.

Exemplo:

`pclass = 1, 2, 3`

Isso é armazenado numericamente, mas não é uma variável *numérica contínua*. É uma variável *categórica ordinal* representando a classe do bilhete.

Atenção: O tipo de dado em memória nem sempre é o mesmo que o tipo estatístico.

Problemas que a EDA tenta mitigar

Estatísticas resudas podem enganar

Média, mediana, desvio-padrão e correlação são úteis, mas comprimem a realidade.

- Uma média pode esconder assimetria.
- Uma correlação pode esconder subgrupos.
- Uma tabela limpa pode esconder contexto histórico ou social.

Problemas que a EDA tenta mitigar

Padrões visuais são hipóteses, não conclusões

Em relação ao dataset Titanic, um gráfico pode sugerir:

- Mulheres tiveram taxas maiores de sobrevivência.
- Passageiros da primeira classe tiveram taxas maiores de sobrevivência.
- Crianças podem ter tido padrões diferentes de sobrevivência.

Mas isso ainda não são afirmações causais.

A EDA nos ajuda a formar hipóteses. Ela não as prova por si só.

Problemas que a EDA tenta mitigar

Modelar sem EDA é perigoso

Sem EDA, podemos:

- Usar o tipo errado de variável;
- Imputar valores ausentes incorretamente;
- Codificar categorias de forma ruim;
- Treinar com vazamento de dados;
- Ignorar desbalanceamento de classes;
- Confiar demais em correlações;
- Deixar de perceber estruturas de subgrupos.

EDA é a ponte entre dados brutos e modelagem responsável, que representa a realidade e cria insights úteis para pessoas, ciência e negócios.

Contexto Histórico

A estatística clássica frequentemente se concentrou em inferência formal: estimar parâmetros, testar hipóteses e tirar conclusões sobre populações a partir de amostras.

A análise exploratória de dados, fortemente associada a **John Tukey**, deslocou a atenção para o ato de olhar diretamente para os dados: encontrar padrões, anomalias, estruturas e perguntas antes de se comprometer com um modelo formal.

Na ciência de dados moderna, a EDA cumpre um papel semelhante: ela nos ajuda a entender o dataset antes do pré-processamento, da engenharia de atributos, da seleção de modelos e da avaliação.

A inferência formal pergunta: “O que podemos concluir?”, a EDA pergunta primeiro: “O que estamos olhando?”

Classificação de Dados Estatísticos

- **Numérico:** Informação expressa em uma escala numérica.
 - **Contínuo:** Dado que pode assumir qualquer valor dentro de um intervalo.
 - Exemplos: altura, peso, temperatura, preço, tempo de execução.
 - Sinônimos: intervalo, flutuante, quantitativo contínuo.
 - **Discreto:** Dado descrito por valores inteiros, geralmente associado a contagens.
 - Exemplos: número de filhos, quantidade de compras, número de acessos.
 - Sinônimos: inteiro, contagem, quantitativo discreto.

Classificação de Dados Estatísticos

- **Categórico:** Dado que assume valores dentro de um conjunto limitado de categorias.
 - **Nominal:** Categoria sem ordenamento natural explícito.
 - Exemplos: cor, cidade, tipo de produto, gênero de filme.
 - Sinônimos: fator, enumeração, classe.
 - **Binário:** Caso especial de dado categórico que assume apenas uma de duas categorias.
 - Exemplos: sim/não, verdadeiro/falso, 0/1, aprovado/reprovado.
 - Sinônimos: dicotômico, lógico, booleano, indicador.
 - **Ordinal:** Categoria com ordenamento explícito, mas sem distância necessariamente uniforme entre os níveis.
 - Exemplos: ruim/regular/bom/ótimo, pequeno/médio/grande, 1º/2º/3º.
 - Sinônimos: fator ordenado, escala ordinal.

Classificação de Dados Computacionais

Extensa lista com exemplos de diversos tipos computacionais encontrados em linguagens de programação, sistemas de bancos de dados e sistemas especializados e seus casos de usos no GitHub do curso.

Dataset Titanic

O dataset Titanic é útil porque é pequeno, intuitivo, historicamente situado e cheio de problemas comuns em dados.

Interpretação:

- Cada linha representa um passageiro.
- Cada coluna representa um atributo registrado sobre esse passageiro.
- A variável-alvo é a sobrevivência.

A pergunta de modelagem é:

Podemos usar informações dos passageiros para estimar a probabilidade de sobrevivência?

Dataset Titanic

Estrutura

- **survived**: Se o passageiro sobreviveu
- **pclass**: Classe do bilhete.
- **sex**: Sexo registrado.
- **age**: Idade do passageiro.
- **sibsp**: Irmãos/cônjuges à bordo.
- **parch**: Pais/filhos à bordo.
- **fare**: Tarifa paga.
- **embarked**: Porto de embarque.
- **ticket**: Número do bilhete.
- **cabin**: Número de cabine.


Atividade: classifiquem a estrutura do dataset em “categórica binária/ordinal/nominal” e “numérica discreta/contínua”

Dataset Titanic

Estrutura

- **survived**: Se o passageiro sobreviveu. (categórica binária)
- **pclass**: Classe do bilhete. (categórica ordinal)
- **sex**: Sexo registrado. (categórica nominal)
- **age**: Idade do passageiro. (numérica discreta)
- **sibsp**: Irmãos/cônjuges à bordo. (numérica discreta)
- **parch**: Pais/filhos à bordo. (numérica discreta)
- **fare**: Tarifa paga. (numérica contínua)
- **embarked**: Porto de embarque. (categórica nominal)
- **ticket**: Número do bilhete. (categórica nominal)
- **cabin**: Número de cabine. (categórica nominal)

Importante notar que os termos “categórica” e “numérica” para tipo estatístico são equivalentes à “qualitativa” e “quantitativa”, respectivamente.



Núcleo de Inteligência Artificial – Universidade LaSalle Canoas

Obrigado pela presença!



Diogo G. Bonofre dos Santos